

**UNIVERSIDAD**

Facultad de Ingeniería

Escuela de Computación

**Infraestructura de Hardware de Vanguardia  
para la Implementación del Model Context  
Protocol (MCP) y la IA Agéntica**

**Materia:** Arquitectura de Computadores

**Presupuesto:** \$2,999.25 USD

**Autores:**

Pedro Cordero 31390900

José García 31630002

**Fecha:** Mayo 2026

# 1. Introducción al Estado Actual del Arte: Más allá del Monoprocesador

La arquitectura de computadores, tal como se define en los fundamentos de David A. Patterson y John L. Hennessy, ha servido como la base para entender la interacción entre el software y el hardware durante décadas. Sin embargo, el contenido académico tradicional a menudo se encuentra con una brecha temporal frente a la velocidad de innovación de la industria actual. Mientras que los textos clásicos se enfocan en la transición de monoprocesadores a sistemas multinúcleo para superar el “muro de la potencia” (Power Wall), el panorama tecnológico de 2024 y 2026 ha dado un salto cualitativo hacia la **IA Agéntica**.

Este informe documenta la investigación y el diseño de una estación de trabajo de **\$2,999.25 USD** optimizada para el **Model Context Protocol (MCP)**. El MCP no es simplemente un avance en la ejecución de instrucciones, sino un estándar abierto propuesto originalmente por Anthropic que **introduce nuevas exigencias en el diseño de la arquitectura del computador**, especialmente en lo referente a comunicación bidireccional y gestión de múltiples fuentes de datos. A nivel de software, el MCP actúa como un estándar de conexión análogo a lo que USB-C representa en el hardware: permite que los modelos de lenguaje (LLM) se conecten de forma estandarizada con herramientas externas, bases de datos y archivos locales.

## 1.1. Justificación de la Selección del Tema: El Ecosistema MCP

La elección de MCP como eje central de este hardware se debe a que este protocolo estandariza la comunicación bidireccional entre tres componentes críticos: el **Host** (la aplicación que contiene el LLM), el **Cliente** (el conector) y el **Servidor** (la fuente de datos o herramienta externa).

Desde el punto de vista de la Arquitectura del Computador, este flujo de trabajo impone exigencias que el libro de texto solo vislumbra en sus capítulos avanzados sobre paralelismo masivo y GPUs. La ejecución de un Host local (como una instancia de Llama-3) requiere una **Unidad de Procesamiento Gráfico (GPU)** con una densidad de VRAM masiva para evitar la degradación de la latencia durante el manejo de ventanas de contexto extensas. Paralelamente, la orquestación de múltiples servidores MCP (SQL, APIs web, sistemas de archivos) demanda una **CPU multinúcleo** capaz de gestionar procesos independientes de forma asíncrona mediante mensajes JSON-RPC 2.0.

## 2. Desglose de la Arquitectura MCP y Demandas de Infraestructura Local

### 2.1. Los Tres Pilares del Ecosistema MCP: Host, Cliente y Servidor

Para comprender por qué un sistema de \$3,000 es necesario, primero debemos desglosar el funcionamiento del protocolo MCP, el cual se estructura en tres componentes funcionales que operan simultáneamente en el sistema operativo:

- **Host de MCP:** Es la aplicación principal (como un IDE de programación, un terminal o una interfaz de chat) que contiene y gestiona el modelo de lenguaje (LLM). El Host actúa como el “cerebro” y el orquestador principal de las peticiones del usuario. En esta configuración, el Host requiere una **GPU masivamente paralela** para procesar la inferencia del modelo sin saturar los recursos del sistema.
- **Cliente de MCP:** Se encuentra dentro del Host y actúa como el traductor universal. Su función es convertir las necesidades de información del LLM en solicitudes estandarizadas para el protocolo y, a su vez, traducir las respuestas del mundo exterior a un formato que el modelo pueda digerir.
- **Servidor de MCP:** Es el componente que proporciona la funcionalidad real. Cada servidor es un proceso independiente encargado de conectar la IA con una fuente de datos específica (como una base de datos SQL, Google Drive, o el sistema de archivos local).

### 2.2. Requerimientos Técnicos para el Despliegue de Servidores

A diferencia de las aplicaciones de oficina tradicionales, el despliegue de un ecosistema basado en MCP exige una arquitectura de hardware que sea capaz de manejar **solicitudes de inferencia concurrentes** y el procesamiento de grandes conjuntos de datos de forma eficiente.

Desde una perspectiva técnica, los servidores MCP se benefician de una CPU con múltiples núcleos (por ejemplo, el Ryzen 9 7900X que seleccionamos tiene 12 núcleos físicos) para garantizar que la orquestación de múltiples conectores no genere cuellos de botella. Por ejemplo, si un agente de IA debe consultar simultáneamente un repositorio de archivos y una base de datos externa, el sistema operativo puede asignar hilos de procesamiento independientes para cada servidor MCP. Un procesador con pocos hilos obligaría a se-

cuencializar estas tareas, aumentando drásticamente el **CPI (Ciclos por Instrucción)** global y degradando la experiencia del usuario.

### 2.3. La Capa de Transporte y el Impacto en el Rendimiento

La comunicación entre el cliente y el servidor en el protocolo MCP se realiza a través de mensajes **JSON-RPC 2.0**. Existen dos métodos principales de transporte que influyen directamente en la selección de los componentes:

- **Entrada/Salida Estándar (stdio)**: Se utiliza para recursos locales. Este método es extremadamente rápido y síncrono, pero depende totalmente de la velocidad del **bus de datos** y de la baja latencia de la memoria RAM.
- **Eventos Enviados por el Servidor (SSE)**: Se prefiere para recursos remotos y permite un streaming de datos eficiente.

En un sistema orientado a agentes autónomos, la velocidad de este intercambio de mensajes es crítica. Un almacenamiento **NVMe de alta velocidad** es esencial para cargar rápidamente los datasets de contexto que los servidores MCP deben enviar al modelo. Sin un ancho de banda masivo en el almacenamiento, el tiempo de respuesta (latencia) del agente se vuelve inaceptable, ya que el procesador desperdiciaría millones de **ciclos de reloj** esperando a que los datos lleguen desde el disco a la memoria principal para ser procesados.

### 2.4. El “Muro de la Memoria” en el Protocolo MCP

Finalmente, la integración de MCP introduce una presión adicional sobre la jerarquía de memoria. No basta con tener mucha memoria RAM; se requiere una baja **penalización por fallo de cache**. El intercambio constante de contexto entre el Host local y los diversos servidores MCP significa que los datos deben entrar y salir de los registros del procesador a una velocidad que solo componentes de última generación (como **DDR5**) pueden sostener. En las siguientes secciones, se detallará cómo la configuración de hardware seleccionada soluciona estas demandas específicas mediante argumentos técnicos de arquitectura multinúcleo.

### 3. Fundamentos de Rendimiento: Ciclos de Reloj y CPI en el Ecosistema MCP

#### 3.1. Definición de Ciclos de Reloj en el Hardware Moderno

Para evaluar la idoneidad de una estación de trabajo de \$3,000 USD para IA, es imperativo analizar la métrica más básica del hardware: el **ciclo de reloj**. Un ciclo de reloj (también llamado *tic* o periodo de reloj) es el intervalo de tiempo discreto en el que el hardware realiza sus funciones básicas. La rapidez con la que el procesador avanza viene determinada por la **frecuencia de reloj** (medida en GHz), que es el inverso del periodo de reloj.

En el contexto de la ejecución local del Model Context Protocol (MCP), cada interacción entre el agente de IA y una herramienta externa implica la ejecución de millones de estos ciclos. El diseño de este computador prioriza procesadores con altas frecuencias de ráfaga (*boost clock*), ya que la latencia percibida por el usuario al interactuar con un agente de IA depende de qué tan rápido la CPU pueda completar los ciclos necesarios para procesar la lógica de las solicitudes JSON-RPC 2.0 que actúan como capa de transporte en MCP.

#### 3.2. La Ecuación de Rendimiento de la CPU Aplicada a Agentes de IA

El rendimiento del sistema no es un valor abstracto, sino el resultado de la ecuación clásica presentada en la sección 1.4 del material de referencia:

$$T_{CPU} = N_{instrucciones} \times CPI \times T_{ciclo} \quad (1)$$

donde:

- $T_{CPU}$  es el tiempo de ejecución de la CPU,
- $N_{instrucciones}$  es el número total de instrucciones del programa,
- $CPI$  son los ciclos por instrucción promedio,
- $T_{ciclo}$  es el tiempo de un ciclo de reloj (inverso de la frecuencia).

Para un sistema orientado a MCP, esta fórmula revela un compromiso crítico. Mientras que el número de instrucciones es determinado por el compilador y el algoritmo del modelo de IA (como Llama-3), el CPI y el tiempo de ciclo dependen directamente del hardware seleccionado. Un sistema de IA eficiente debe aspirar a un CPI bajo para procesar grandes

volúmenes de datos de contexto en el menor tiempo posible. Al integrar múltiples servidores MCP (SQL, buscadores, archivos), el procesador debe gestionar ráfagas asíncronas de instrucciones donde un CPI elevado en un solo hilo podría bloquear la interactividad de todo el agente agéntico.

### 3.3. El Impacto de la Arquitectura Multinúcleo y el CPI Global

Siguiendo la tendencia tecnológica explicada en clase, la industria ha pasado de buscar frecuencias de reloj infinitas a **duplicar el número de núcleos** cada dos años para superar el “muro de la potencia”. En nuestra configuración de \$3,000, la selección de un microprocesador multinúcleo es fundamental porque permite que el sistema maneje el paralelismo a nivel de hilos (MIMD).

En un entorno MCP, esto significa que mientras un grupo de núcleos mantiene un CPI optimizado para la inferencia del modelo en la GPU, otros núcleos independientes gestionan la latencia de los servidores de contexto. Si intentáramos ejecutar este protocolo en un procesador antiguo de pocos núcleos, las dependencias de datos y los riesgos de control generarían **bloqueos del pipeline** (burbujas), disparando el CPI promedio y degradando el tiempo de respuesta total del sistema.

### 3.4. Ley de Amdahl y el Escalado de Servidores de Contexto

Finalmente, la eficiencia de nuestra PC de \$3,000 está sujeta a la **Ley de Amdahl**:

$$S = \frac{1}{(1 - P) + \frac{P}{N}}$$

donde  $S$  es la aceleración (*speedup*),  $P$  es la fracción paralelizable del programa y  $N$  es el número de núcleos. Esta ley establece que la mejora de las prestaciones está limitada por la fracción del programa que no puede beneficiarse de la mejora. En un sistema MCP, si el software que conecta la IA con la base de datos es puramente secuencial, añadir más núcleos no reducirá el tiempo de ejecución. Por ello, el hardware seleccionado (Ryzen 9 7900X) se justifica técnicamente no solo por su potencia bruta, sino por su capacidad de minimizar la sobrecarga de planificación y coordinación entre los servidores MCP, permitiendo un **escalado fuerte** de las tareas de la IA.

## 4. La Unidad de Procesamiento (CPU): Arquitectura Multinúcleo y Orquestación de Agentes

### 4.1. Superación del “Muro de la Potencia” y la Era Multinúcleo

La arquitectura del sistema de \$3,000 USD propuesto debe responder a una de las limitaciones físicas más importantes discutidas en la sección 1.5 del libro de texto: el **muro de la potencia**. Históricamente, el rendimiento de los computadores crecía aumentando la frecuencia de reloj, pero este enfoque se volvió inviable debido a los límites prácticos de disipación de calor y las fugas de corriente. En lugar de continuar reduciendo el tiempo de respuesta de un único programa en un monoprocesador, la industria se vio forzada a migrar hacia los **microprocesadores multinúcleo**, que contienen varios núcleos en un único circuito integrado.

Para un ecosistema orientado a MCP, la selección de la CPU no puede basarse únicamente en la velocidad bruta (GHz), sino en su capacidad para manejar el paralelismo a nivel de hilos. Se ha seleccionado el **AMD Ryzen 9 7900X** (\$360 USD), un procesador con **12 núcleos y 24 hilos** de ejecución. Esta elección se justifica técnicamente porque la tendencia actual, descrita por Patterson y Hennessy, es duplicar el número de núcleos cada dos años para mejorar las prestaciones globales sin disparar el consumo energético.

### 4.2. Justificación Técnica: El Procesador como Orquestador de MCP

En la arquitectura del Model Context Protocol, el rol de la CPU es radicalmente distinto al de una PC convencional. Mientras que la GPU se encarga del procesamiento masivamente paralelo del modelo (SIMD), la CPU actúa como el orquestador del tráfico mediante el paralelismo a nivel de tareas (MIMD).

Cada **servidor MCP** (que conecta la IA con una base de datos SQL, una API de búsqueda o un sistema de archivos local) corre como un **proceso independiente** en el sistema operativo. Esto significa que, en una sesión de trabajo con un agente de IA agéntica, pueden estar activos simultáneamente tres o cuatro servidores MCP. Una CPU de muchos núcleos permite:

- **Reducir la contención por recursos:** Al tener suficientes hilos (24 en este caso), el sistema operativo puede asignar hilos dedicados a cada servidor MCP, evitando que las solicitudes JSON-RPC 2.0 tengan que competir por los mismos núcleos.

- **Reducción de riesgos de control:** Al distribuir las tareas asíncronas del protocolo MCP entre núcleos físicos distintos, se reduce la probabilidad de bloqueos del pipeline (burbujas) causados por dependencias de datos entre las llamadas a herramientas externas y la inferencia del modelo.

### 4.3. Análisis de Rendimiento: CPI y Ciclos de Orquestación

Aplicando los conceptos de la sección 1.4, el rendimiento de este procesador en el contexto de MCP se analiza a través de los ciclos por instrucción (CPI). Un procesador multinúcleo avanzado como el seleccionado utiliza técnicas de **ejecución múltiple** (superescalar), permitiendo lanzar varias instrucciones por ciclo de reloj, lo que puede resultar en un CPI menor a 1 (o un IPC mayor a 1).

Para que el protocolo MCP funcione de manera fluida, la CPU debe gestionar ráfagas de mensajes JSON-RPC. El AMD Ryzen 9 7900X permite que el “Host” de la IA procese la lógica de respuesta mientras los servidores MCP recuperan datos de contexto en segundo plano, maximizando la productividad del sistema (*throughput*). Sin esta capacidad multinúcleo, el procesador se encontraría con el “muro de la memoria”, desperdiciando millones de ciclos de reloj esperando a que los servidores de contexto devuelvan la información solicitada.

### 4.4. Eficiencia Energética en Cargas de Trabajo de IA

Finalmente, la nota de diseño recalca que el uso de muchos núcleos pequeños y eficientes es energéticamente preferible a un único núcleo grande e ineficiente. Dado que el presupuesto de potencia de nuestra PC está limitado por una fuente de poder de 1000W para dar soporte a la GPU, el Ryzen 9 7900X ofrece un equilibrio óptimo entre **prestaciones por vatio** y capacidad de paralelismo. Esto asegura que el sistema pueda mantener una orquestación de agentes de IA compleja sin exceder los límites térmicos que causarían una reducción forzada de la frecuencia de reloj (*thermal throttling*).



## 5. El Núcleo de la Inferencia de IA: Procesamiento Paralelo Masivo (GPU)

### 5.1. Justificación Técnica: La GPU como Acelerador de Inferencia

Dentro de la arquitectura del sistema de \$3,000 USD que estamos diseñando, la GPU no cumple una función meramente gráfica, sino que actúa como un **acelerador de computación masivamente paralelo**. Según los fundamentos de hardware moderno, mientras que la CPU se optimiza para minimizar la latencia de un solo hilo (control), la GPU se diseña para maximizar la **productividad (*throughput*)** de miles de hilos concurrentes.

Se ha seleccionado la **NVIDIA RTX 4090 (24GB VRAM)**, con un costo estimado de \$1,750 USD, representando el 58 % del presupuesto total. Esta decisión no se basa en publicidad comercial, sino en parámetros técnicos reales: para actuar como un “Host” local en el ecosistema MCP, el sistema debe ser capaz de albergar modelos de lenguaje (LLM) de gran tamaño, como Llama-3 de 70B o versiones cuantizadas de modelos superiores. Un modelo de tamaño medio requiere entre 8GB y 14GB de VRAM solo para cargarse en memoria, dejando el resto de la capacidad para gestionar ventanas de contexto extensas sin recurrir a la memoria RAM del sistema, la cual es significativamente más lenta.

### 5.2. Arquitectura de Hardware: Del Modelo SIMD al Paradigma SIMT

Para el informe, es crucial distinguir entre la arquitectura **SIMD** (Single Instruction, Multiple Data) mencionada en el libro y el modelo **SIMT** (Single-Instruction, Multiple-Threads) que utiliza la arquitectura NVIDIA:

- **SIMD Tradicional:** El hardware exige que el software exprese explícitamente el paralelismo de datos en cada instrucción vectorial.
- **SIMT en RTX 4090:** Permite que los hilos individuales (*threads*) sigan sus propias vías de ejecución de forma independiente, pero se agrupan en **tramas (*warps*)** de 32 hilos para ejecutarse con eficiencia síncrona cuando las instrucciones coinciden.

Esta distinción es vital para el Model Context Protocol, ya que el procesamiento de mensajes JSON-RPC 2.0 y la búsqueda de contexto en bases de datos vectoriales a menudo implican divergencias en el flujo de control. La arquitectura SIMT de la RTX 4090 permite que los hilos de la IA operen de forma independiente si es necesario, minimizando las

penalizaciones por divergencia en el pipeline.

### 5.3. El Desafío del Contexto: VRAM y el “Muro de la Memoria”

Un argumento técnico central en este informe es el manejo del **ancho de banda de memoria**. Las cargas de trabajo de IA agéntica son extremadamente exigentes en cuanto a la transferencia de datos. La RTX 4090 soluciona el “muro de la memoria” mediante la utilización de memoria **GDDR6X**, diseñada específicamente para anchos de banda masivos que superan los 1,000 GB/s.

En un sistema MCP, el “Cliente” solicita información que el “Servidor” debe inyectar en el contexto del modelo. Si este intercambio de contexto no ocurre a velocidades de terabytes por segundo dentro de la GPU, el procesador desperdiciaría millones de ciclos de reloj en estados de espera (*stalls*), degradando el rendimiento del agente de IA. Además, el uso de técnicas de compresión sin pérdidas en la unidad ROP (*Raster Operations Processor*) de esta GPU permite optimizar el ancho de banda efectivo durante las operaciones de lectura-escritura intensas de los datasets de contexto.

### 5.4. Consumo Energético y Ciclos de Ejecución

Finalmente, la elección de esta GPU impone una demanda eléctrica de **450W de carga pico**. Desde la perspectiva de la arquitectura de computadores, este consumo es el precio a pagar por la densidad de cálculo necesaria para mantener un CPI bajo en tareas de inferencia. Al tener miles de núcleos trabajando en paralelo, la GPU puede completar en un solo ciclo de ráfaga lo que a la CPU le tomaría miles de ciclos secuenciales, resultando en una eficiencia energética superior por cada tarea de IA completada, a pesar de su alto consumo energético.

## 6. Jerarquía de Memoria y Almacenamiento: Intercambio de Contexto Ultrarrápido

### 6.1. Memoria de Acceso Aleatorio (RAM): Superando el “Muro de la Memoria”

En la arquitectura tradicional descrita en el libro de texto, la memoria principal implementada con DRAM ha sido históricamente el cuello de botella debido a que su tiempo de acceso (nanosegundos) es órdenes de magnitud más lento que los ciclos de reloj del procesador. Para el ecosistema MCP, donde se requiere orquestar simultáneamente un Host de IA y múltiples servidores de contexto, la gestión de la memoria es crítica.

Se han seleccionado **64GB de memoria DDR5 a 6000MHz** (\$210 USD). Esta elección se justifica técnicamente por la necesidad de minimizar la **penalización por fallo de cache**. En un flujo de trabajo de IA agéntica, los datos de contexto (como tablas SQL o archivos locales) deben cargarse desde la memoria principal a las caches L1/L2 del procesador para ser procesados por los mensajes JSON-RPC del protocolo. El uso de tecnología DDR5 proporciona un ancho de banda masivo en comparación con las DDR4 mencionadas en casos de estudio antiguos, permitiendo que el procesador mantenga su pipeline lleno y reduzca los **ciclos de parada** (*stalls*) por espera de datos.

### 6.2. Almacenamiento Persistente: El Rol del NVMe en el Protocolo MCP

El almacenamiento en un sistema MCP no es solo un depósito de archivos, sino una extensión de la jerarquía de memoria que impacta directamente en la latencia del agente. Se ha presupuestado un **NVMe Gen4 de 2TB** (\$160 USD).

Desde la perspectiva de la arquitectura de computadores, el tiempo medio de acceso a memoria (AMAT) se dispara cuando el sistema debe recurrir al nivel más bajo de la jerarquía (almacenamiento). Un fallo de página o la carga de un dataset masivo desde un disco duro tradicional tardaría millones de ciclos de reloj. En cambio, un NVMe Gen4 reduce drásticamente la **latencia de acceso** (del orden de microsegundos) y proporciona un **alto ancho de banda** (del orden de gigabytes por segundo), lo que permite transferir grandes bloques de contexto rápidamente. Así, cuando un servidor MCP requiere “inyectar” contexto al modelo, la información viaja al bus de datos a alta velocidad, minimizando el tiempo que la IA permanece inactiva esperando la entrada/salida (E/S).

### 6.3. Impacto en las Prestaciones: Ciclos de Parada y CPI

Aplicando la teoría de rendimiento vista en clase, la eficiencia del sistema MCP se ve degradada por los ciclos de reloj de parada debido a la memoria. La ecuación fundamental es:

$$\text{Ciclos de parada} = \frac{\text{Accesos a memoria}}{\text{Programa}} \times \text{Tasa de fallos} \times \text{Penalización por fallo}$$

Si seleccionáramos una memoria RAM más lenta o un almacenamiento de menor categoría para ahorrar presupuesto, la penalización por fallo aumentaría, lo que elevaría el CPI global del sistema. En nuestras pruebas de diseño, un sistema con almacenamiento NVMe premium permite que el Host de IA mantenga una interactividad fluida, ya que los servidores de contexto pueden recuperar y transmitir datos mediante JSON-RPC en una fracción de los ciclos que requeriría una arquitectura basada en discos magnéticos o SSDs de primera generación.

### 6.4. Localidad de Datos y Contexto Agéntico

Finalmente, la configuración de 64GB de RAM permite aprovechar el **principio de localidad temporal**. Una vez que un servidor MCP recupera información relevante (como un manual técnico para el LLM), es probable que el modelo vuelva a consultar esa información en ciclos sucesivos. Mantener grandes bloques de contexto en la memoria RAM de alta velocidad evita accesos repetitivos al almacenamiento persistente, reduciendo la carga sobre el bus de sistema y permitiendo que los 24 hilos del procesador Ryzen 9 se enfoquen en la orquestación lógica del protocolo en lugar de en la gestión de esperas de E/S.

## 7. Infraestructura Eléctrica: Estimación de Consumo y Eficiencia Energética

### 7.1. Análisis Técnico del Consumo Energético (Wattage)

La construcción de una estación de trabajo para IA agéntica de \$2,999.25 USD exige una fuente de alimentación que no solo suministre energía, sino que actúe como un estabilizador para los picos de demanda del hardware de vanguardia. Según los requisitos del curso, no se deben elegir piezas basándose en publicidad, sino en cálculos técnicos reales.

Para nuestro sistema optimizado para MCP, el cálculo del consumo total se desglosa de la siguiente manera:

- **GPU (NVIDIA RTX 4090):** Carga pico de **450W** durante procesos de inferencia masiva.
- **CPU (AMD Ryzen 9 7900X):** TDP de **170W** bajo carga de orquestación multihilo.
- **Componentes Periféricos:** Placa base, RAM, NVMe y refrigeración suman **90W**.

La demanda total combinada bajo estrés máximo es:

$$P_{total} = P_{GPU} + P_{CPU} + P_{perifricos} = 450 + 170 + 90 = 710 \text{ W}$$

Siguiendo la recomendación técnica de mantener un margen de holgura del 30 %:

$$P_{requerida} = P_{total} \times 1,30 = 710 \times 1,30 = 923 \text{ W}$$

Por lo tanto, se ha seleccionado una fuente de **1000W**, que supera el mínimo teórico de 923W y proporciona estabilidad operativa.

### 7.2. Cálculo de Amperaje en el Riel de 12V

El cálculo del amperaje en el riel principal de 12V, que alimenta tanto la GPU como la CPU:

$$I = \frac{P}{V} = \frac{710}{12} = 59,17 \text{ A (bajo carga pico)}$$

La fuente de 1000W seleccionada proporciona un riel de 12V capaz de suministrar hasta 83.3A ( $1000/12$ ), otorgando un margen operativo suficiente para absorber los picos transitorios de la RTX 4090.

### 7.3. Curvas de Eficiencia y Certificación 80+ Gold

La elección de una fuente de 1000W con certificación 80+ Gold no es arbitraria. Las fuentes de poder alcanzan su máxima eficiencia energética cuando operan entre el 50 % y el 70 % de su capacidad total. En nuestro escenario de ejecución de MCP, donde la carga típica rondará los 500W–600W, el sistema trabajará en el punto dulce de la curva de eficiencia, minimizando la disipación de calor residual y reduciendo el ruido eléctrico que podría afectar la estabilidad de las señales digitales.

### 7.4. El Estándar ATX 3.0 y Picos Transitorios

Un aspecto crítico es el comportamiento de la arquitectura NVIDIA de la serie 40, conocida por presentar “picos transitorios” de energía que pueden duplicar momentáneamente el consumo nominal. Para mitigar este riesgo, la configuración incluye una fuente compatible con el estándar **ATX 3.0**. Este estándar está diseñado específicamente para hardware de IA moderno, ya que incluye el conector nativo **12VHPWR (PCIe 5.0)**, capaz de suministrar hasta 600W de forma estable a través de un solo cable, eliminando la necesidad de adaptadores que aumentan la resistencia eléctrica y el riesgo térmico.

## 8. Gestión Térmica: El Desafío de la Refrigeración en Sistemas de IA

### 8.1. El “Muro de la Potencia” y la Disipación Térmica

Uno de los conceptos fundamentales en la arquitectura de computadores moderna es el **muro de la potencia**, descrito en la sección 1.5 del material de referencia. Históricamente, el aumento de la frecuencia de reloj y la densidad de transistores ha llevado a un incremento proporcional en la disipación de calor. Según las fuentes, un microprocesador de alto rendimiento puede consumir y, por lo tanto, debe extraer más de 120 vatios de un chip de apenas 1 cm<sup>2</sup>.

En nuestro sistema diseñado para el MCP, este desafío se intensifica. La ejecución de un Host local de IA junto con múltiples servidores de contexto genera lo que se conoce como **potencia dinámica**, la cual se consume durante las transiciones de los transistores:

$$P_{dinmica} = C \times V^2 \times f$$

donde  $C$  es la capacitancia de carga,  $V$  es el voltaje y  $f$  es la frecuencia de conmutación. Si el calor generado no se extrae de manera eficiente, el procesador activa mecanismos de protección térmica que reducen la frecuencia de reloj (*thermal throttling*), alargando el tiempo de ciclo y degradando drásticamente el rendimiento del agente de IA.

### 8.2. Selección Técnica: Sistema de Refrigeración Líquida AIO de 360mm

Para mitigar estos riesgos, se ha presupuestado un sistema de **refrigeración líquida All-In-One (AIO) de 360mm** (\$115 USD). Esta elección no responde a criterios estéticos o publicitarios, sino a una necesidad de ingeniería térmica. Un radiador de 360mm proporciona una superficie de intercambio de calor masiva que actúa como un elemento con alta capacidad de disipación térmica ante las fluctuaciones agresivas de temperatura inherentes a la inferencia de IA.

A diferencia de los disipadores de aire convencionales, la refrigeración líquida permite que el procesador AMD Ryzen 9 7900X mantenga sus algoritmos de auto-overclock (como *Precision Boost Overdrive*) de manera sostenida. Esto es vital para que el tiempo de ejecución de la CPU se mantenga mínimo, asegurando que cada instrucción del protocolo

MCP se complete en la menor cantidad de nanosegundos posible sin interrupciones por sobrecalentamiento.

### 8.3. Impacto de la Temperatura en los Ciclos de Reloj y el Rendimiento

Siguiendo la lógica de las prestaciones, el rendimiento se mide por el tiempo que la CPU tarda en computar una tarea específica. Un sistema de refrigeración deficiente aumenta indirectamente el CPI al forzar al procesador a insertar ciclos de espera o reducir su velocidad para enfriarse.

En un entorno de agentes dinámicos MCP, donde la interactividad es clave, el sistema de refrigeración garantiza la proporcionalidad energética y operativa. Al mantener la GPU RTX 4090 y la CPU Ryzen dentro de rangos térmicos óptimos (por debajo de 80°C bajo carga sostenida), aseguramos que el ancho de banda de la memoria y la velocidad de procesamiento de hilos no se vean limitados por el entorno físico.

### 8.4. Flujo de Aire y Diseño del Gabinete

Finalmente, la gestión térmica no depende solo del líquido refrigerante, sino del diseño del chasis. Se ha seleccionado el gabinete **Corsair 4000D Airflow** (\$54.25 USD). Su panel frontal perforado está técnicamente diseñado para maximizar la entrada de aire fresco, reduciendo la temperatura ambiente interna que afecta a los reguladores de voltaje (VRM) de la placa madre y a la memoria VRAM de la GPU. Este enfoque sistémico de la refrigeración permite que el equipo de \$3,000 USD funcione como una infraestructura de grado profesional, capaz de operar al 100% de carga durante periodos prolongados de intercambio de contexto agéntico.



## 9. Cuadro de Componentes y Presupuesto Detallado

### 9.1. Metodología de Selección y Captura de Precios

Siguiendo las instrucciones de la cátedra, los precios aquí reflejados corresponden a una investigación de mercado en tiempo real en plataformas como Amazon y Newegg. Se han incluido capturas de pantalla (referenciadas en los anexos del informe físico) para validar el costo en el momento de la toma de decisión, garantizando que el presupuesto no sufra desviaciones por la volatilidad del mercado de semiconductores. El objetivo técnico es maximizar el valor añadido por cada dólar, priorizando la capacidad de VRAM, el paralelismo de hilos y la estabilidad térmica.

## 9.2. Tabla Maestra de Hardware para Ecosistema MCP

| ComponenteModelo |                             | Justificación Técnica (MCP)                                                                                   | Costo             |
|------------------|-----------------------------|---------------------------------------------------------------------------------------------------------------|-------------------|
| GPU              | NVIDIA RTX 4090 24GB        | Host local de LLMs. 24GB VRAM para ventanas de contexto extensas sin degradar latencia. Arquitectura SIMT.    | \$1,750.00        |
| CPU              | AMD Ryzen 9 7900X (12C/24T) | Orquestación de servidores MCP independientes. 24 hilos para paralelismo MIMD en JSON-RPC.                    | \$360.00          |
| Placa Madre      | MSI MAG B650 Tomahawk WiFi  | Ancho de banda PCIe 4.0/5.0. Bus sin cuellos de botella para GPU y NVMe.                                      | \$195.00          |
| Memoria RAM      | 64GB (2x32GB) DDR5 6000MHz  | Datasets de contexto en memoria principal. Reducción de fallos de cache y ciclos de parada.                   | \$210.00          |
| Almacenamiento   | 2TB NVMe Gen4 (7450 MB/s)   | Lectura ultrarrápida de logs y archivos. Baja latencia y alto ancho de banda para transferir contexto al LLM. | \$160.00          |
| Fuente de Poder  | 1000W 80+ Gold ATX 3.0      | Picos transitorios GPU. Cable 12VHPWR nativo. Margen 30 % sobre 710W pico.                                    | \$155.00          |
| Refrigeración    | Líquida AIO 360mm           | Alta capacidad de disipación térmica para carga sostenida de IA. Evita <i>thermal throttling</i> .            | \$115.00          |
| Gabinete         | Corsair 4000D Air-flow      | Flujo de aire para evacuar hasta 710W térmicos.                                                               | \$54.25           |
| <b>TOTAL</b>     |                             | <b>Presupuesto exacto según requerimiento</b>                                                                 | <b>\$2,999.25</b> |

Cuadro 1: Desglose de componentes y costos para estación de trabajo MCP.

### 9.3. Justificación del Valor Añadido al Proyecto de IA

La selección de estos componentes no responde a una configuración “comercial” o de “gaming”, sino a una necesidad de infraestructura técnica adaptada al presupuesto de \$3,000:

- **Eficiencia en la inferencia:** Al invertir más del 58 % en la GPU, se reduce el tiempo de inferencia de minutos a segundos, optimizando los ciclos de ráfaga.
- **Conectividad MCP:** El uso de una placa base con soporte PCIe 5.0 y almacenamiento NVMe de alto rendimiento asegura que el protocolo funcione como un estándar de conexión fluido.
- **Holgura Eléctrica:** El margen del 30 % en la fuente protege la inversión contra el desgaste de los capacitores y permite operar en la zona de máxima eficiencia.

## 10. Conclusión: La Nueva Frontera de la Arquitectura Multinúcleo y la IA Agéntica

### 10.1. Síntesis de la Infraestructura Técnica

La culminación de este proyecto de diseño de hardware, con un presupuesto estricto de \$2,999.25 USD, demuestra que la arquitectura del computador ha dejado de ser un soporte pasivo para programas secuenciales y se ha transformado en un orquestador activo de inteligencia. A través del protocolo MCP (Model Context Protocol), hemos integrado los tres pilares del ecosistema (Host, Cliente y Servidor) en una máquina física capaz de superar las limitaciones de conocimiento “congelado” de los modelos de lenguaje tradicionales.

Técnicamente, la selección de una NVIDIA RTX 4090 y un AMD Ryzen 9 7900X no solo responde a una necesidad de potencia bruta, sino a una optimización de los ciclos de ráfaga y una minimización del CPI global. Al utilizar una arquitectura masivamente paralela (SIMT) para la inferencia y una arquitectura multinúcleo (MIMD) para la gestión asíncrona de servidores de contexto, este equipo garantiza que la latencia de los mensajes JSON-RPC 2.0 no degrade la interactividad del agente.

### 10.2. El MCP como Estándar de Interoperabilidad

Tal como los arquitectos de computadores han buscado históricamente un sistema potente conectando computadores más pequeños (una visión descrita como el “El Dorado” del diseño), el protocolo MCP alcanza esta meta a nivel de software y datos, sin necesidad de modificar la arquitectura subyacente del procesador. Al actuar como un estándar de conexión para la IA, permite que un agente local pueda escalar de una simple tarea de chat a la gestión de una fuerza de trabajo digital empresarial.

Este informe confirma que el escalado de estos sistemas ya no depende únicamente de aumentar la frecuencia de reloj —limitada por el muro de la potencia— sino de la capacidad de duplicar núcleos y optimizar el ancho de banda de la jerarquía de memoria. La configuración propuesta de 64GB DDR5 y NVMe Gen4 es la respuesta técnica al “muro de la memoria”, asegurando que el procesador no desperdicie ciclos de parada esperando datos de contexto críticos.

### 10.3. Reflexión Académica Final

Aunque los fundamentos de la arquitectura MIPS 32 presentados en el libro de Patterson y Hennessy proporcionan la base lógica necesaria para entender los registros y las instrucciones de bajo nivel, la rapidez con la que evoluciona el hardware exige que el estudiante de ingeniería se involucre en el estado actual del arte. Este trabajo ha servido como puente entre la teoría clásica de los ciclos de ejecución y las demandas modernas de la IA Agéntica.

En conclusión, el computador de \$3,000 aquí diseñado no es solo una suma de componentes certificados y sistemas de refrigeración de alto rendimiento; es una plataforma de **computación heterogénea** preparada para el futuro. La transición de sistemas SISD a ecosistemas complejos que aprovechan el paralelismo a nivel de datos y de hilos es lo que permitirá que la inteligencia artificial pase de ser una herramienta estática a un agente dinámico capaz de interactuar y transformar el mundo real.

---

## Referencias

- [1] Patterson, D. A., & Hennessy, J. L. (2011). *Estructura y diseño de computadores* (4<sup>a</sup> ed.). Barcelona: Reverté. (Título original: *Computer Organization and Design*).
- [2] Anthropic. (2024). *Model Context Protocol (MCP) – Documentación oficial*. Recuperado de <https://modelcontextprotocol.io/>